

# 基於強化學習的動態迷宮智能體：以「迷宮之主」實現動態難度調整

蔡易龍

正修科技大學 41311202 蔡易龍

[41311202@gcloud.csu.edu.tw](mailto:41311202@gcloud.csu.edu.tw)

高詮鈞

正修科技大學 41311138 高詮鈞

[41211138@gcloud.csu.edu.tw](mailto:41211138@gcloud.csu.edu.tw)

黎氏嬌榮

正修科技大學 41111148 黎氏嬌榮

[41111148@gcloud.csu.edu.tw](mailto:41111148@gcloud.csu.edu.tw)

## Abstract

本專案旨在設計一個基於強化學習(RL)的動態迷宮系統，其核心創新在於將學習智能體(Agent)由「玩家」轉移至「迷宮之主」。系統包含玩家、小怪與「迷宮之主」三個角色。傳統迷宮設計多為靜態或隨機生成，缺乏適應玩家行為的動態調整機制。為解決此問題，我們提出一個「迷宮之主」智能體，其利用強化學習技術，根據玩家的即時狀態(如位置、血量、遊戲進程)動態調整迷宮的出口位置與內部結構(如牆壁)。本研究預計採用深度Q網路(DQN)結合程序化內容生成(PCGRL)與動態難度調整(DDA)技術，訓練智能體學習最佳策略，以期在遊戲過程中產生具持續挑戰性與多樣性的迷宮體驗。

## 1. Introduction

強化學習(Reinforcement Learning, RL)已被廣泛應用於訓練智能體解決迷宮問題，例如透過 Q-learning 或深度強化學習(DRL)演算法訓練角色尋找最優路徑。然而，這些研究大多將「玩家」或「角色」作為學習的對象，而

忽略了遊戲環境本身也可以作為智能體的一部份進行學習與調整。

在傳統遊戲設計中，迷宮地圖往往是靜態生成或基於簡單隨機算法生成，這種設計缺乏對玩家行為的即時反饋與適應性。靜態設計可能導致玩家在熟悉地圖後感到挑戰性不足，或者在初期遭遇過高難度，進而影響整體的遊戲體驗與沉浸感。

為此，本研究提出一個核心問題：如何設計一個「迷宮之主」(Dungeon Master)智能體，使其能夠根據玩家的行為動態生成出口位置、調整迷宮布局，並透過召喚小怪等行為影響遊戲進程，以達到動態難度調整(Dynamic Difficulty Adjustment, DDA)的效果。我們嘗試將強化學習的主體由「玩家」轉移至「迷宮」，讓迷宮本身具備學習與適應能力。

### 1.1 Existing Solution

本研究建立在兩個主要的相關領域之上：程序化內容生成(PCG)與動態難度調整(DDA)。

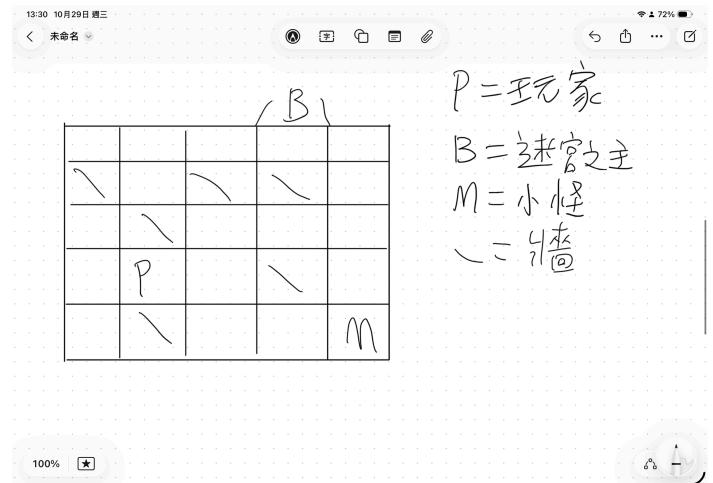
- 程序化內容生成 (PCG):  
PCG 技術允許透過演算法自動生成遊戲關卡，減少人工設計成本並增加多樣性。近年來，PCGRL (Procedural Content Generation via Reinforcement Learning) 提供了一種將地圖生成建模為馬可夫決策過程 (MDP) 的框架。Agent 透過一系列動作 (如放置磚塊) 來建構關卡，並根據生成關卡的可玩性獲得獎勵。
- 動態難度調整 (DDA):  
DDA 旨在根據玩家表現即時調整遊戲參數，以維持玩家的「心流」(Flow) 體驗。傳統 DDA 多依賴靜態規則腳本 (例如：若玩家連續失敗 3 次，則不召喚小怪或降低迷宮佈局改變頻率)。而基於強化學習的 DDA (RL-based DDA) 則嘗試讓 Agent 學習一套動態調整策略，以更精準地適應玩家。

## 1.2 Expected Solution

本研究的創新點在於將 PCGRL 與 RL-based DDA 結合，使「迷宮之主」不僅能調整現有參數 (DDA)，更能動態改變環境結構本身 (PCGRL)，從而提供更深層次的動態遊戲體驗。我們的核心假設是：此結合將能創造出比傳統靜態迷宮更具挑戰性與可玩性的遊戲體驗。

## 2. Method

我們的目標是訓練一個「迷宮之主」智能體 (Agent)。本節將詳細描述系統架構、馬可夫決策過程 (MDP) 的定義，以及我們選用的演算法。



### 2.1 Architecture

我們設計一個閉環 (Closed-loop) 學習系統，其運作流程如下：

1. **玩家行動**: 玩家在  $N \times N$  的迷宮環境中移動，其行為 (移動、使用道具、被攻擊) 會改變環境狀態。
2. **狀態觀測**: 玩家每行動  $k$  步 (例如  $k = 5$ )，「迷宮之主」Agent 觀測一次當前的全局狀態  $s_t$ 。
3. **Agent 決策**: Agent 的神經網路模型 (DQN) 根據狀態  $s_t$  輸出一系列動作的 Q-value，並依  $\epsilon - greedy$  策略選擇一個動作  $a_t$  (例如：在  $(x,y)$  放置牆壁)。
4. **環境更新**: 環境執行動作  $a_t$ ，更新為新狀態  $s_{t+1}$  (例如迷宮結構改變)。
5. **獎勵計算**: 系統根據  $s_{t+1}$  所體現的遊戲挑戰度，計算一個即時獎勵  $r_t$  並回傳給 Agent。
6. **經驗儲存與學習**: 將  $(s_t, a_t, r_t, s_{t+1})$  存入經驗回放池 (Replay Buffer) 中，用於 Agent 的離線訓練。

### 2.2 馬可夫決策過程 (MDP) 定義

我們從「迷宮之主」Agent 的視角來定義 MDP：

- 狀態 (State, S):

我們採用完全資訊的狀態表示法。狀態  $s_t$  是一個  $N \times N \times C$  的張量 (Tensor), 其中  $N \times N$  是迷宮尺寸, 先暫定為  $15 \times 15$ :

- $C_1$ : 牆壁位置 (0=空, 1=牆)
- $C_2$ : 玩家位置 (0=無, 1=玩家)
- $C_3$ : 小怪位置 (0=無, 1=小怪)
- $C_4$ : 出口位置 (0=無, 1=出口)
- $C_5$ : 玩家血量 (歸一化值 0.0 ~ 1.0)

- 動作 (Action, A):

Agent 的動作空間是離散的。為了簡化問題, 我們定義的動作  $a_t$  包含:

- **No-op**: 不執行任何動作。
- 改變出口: 將出口移動到指定  $M$  個候選位置之一。
- 改變牆壁: 在玩家鄰近  $k \times k$  範圍內的  $(x,y)$  座標生成一面牆。
- 消除牆壁: 在玩家鄰近  $k \times k$  範圍內的  $(x,y)$  座標消除一面牆。
- 召喚小怪: 在玩家鄰近  $k \times k$  範圍內的  $(x,y)$  座標召喚一隻小怪。

- 獎勵 (Reward, R):

獎勵函數  $R_t$  的設計旨在平衡遊戲的挑戰性:

- 維持挑戰 (正獎勵):
  - 玩家被小怪攻擊 (非致命):  
 $R += 5$
  - 玩家通關時間在「理想區間」 $[T_{min}, T_{max}]$  內:  
 $R_{final} = +100$
- 懲罰無聊/過難 (負獎勵):
  - 玩家過快通關 ( $T < T_{min}$ ):  
 $R_{final} = -100$
  - 玩家受困過久 ( $T > T_{max}$ ):  
 $R_{final} = -100$
  - 玩家在同區域停留過久 (e.g., > 30秒):  
 $R = -1$

- 玩家血量過低 (e.g., < 20%):  
 $R = -5$  (避免難度過高)

## 2.3 Algorithm

我們分析了幾種潛在的 DDA 實現方法 (如表 1 所示)。考量到我們高維度的狀態空間 ( $N \times N$  地圖) 與對學習能力的需求, 我們最終選擇使用深度 Q 網路 (DQN)。

表 1: 不同 DDA 實現方法的比較

方法選項	優點	缺點 / 為何不選
靜態腳本	實現簡單 (e.g., IF-THEN)	模式固定、易被識破、無學習能力
DQN (選用)	可行: 可用 CNN 處理高維狀態	需大量模擬訓練、調參複雜
策略梯度 (PG)	可行: 可學習隨機策略	訓練變異數 (variance) 高、收斂稍慢

我們選用 DQN 作為「迷宮之主」Agent 的核心演算法。我們將使用一個卷積神經網路 (CNN) 來自動提取  $N \times N$  狀態地圖的特徵, 網路的輸出層為一個全連接層, 其節點數對應動作空間  $N$  的維度, 輸出每個動作的 Q-value。

## 3 Experiment

為了驗證我們方法的有效性, 我們設計了以下實驗流程。

### 3.1 Environment

我們將比較兩個版本的迷宮：(A) 傳統靜態迷宮(固定布局)，以及(B)由我們訓練好的DQN「迷宮之主」動態調整的迷宮。

### 3.2 Training Data

強化學習不需要靜態資料集，而是依賴於與模擬環境的互動。

- **玩家模擬 (Bot)**: 在訓練階段，為了產生大量的訓練資料，「玩家」角色將由一個模擬智能體(Bot)扮演。
- **Bot 演算法**: 我們使用 A\* (A-star) 尋路演算法來模擬玩家。此 Bot 的目標是「不惜一切代價盡快找到出口」，它將作為「迷宮之主」Agent 的訓練對手。

### 3.3 Metrics

評估指標將包括：

1. **平均通關時間**: 我們預期 (B) 的通關時間會高於 (A)，但標準差會更小，顯示難度被穩定控制。
2. **玩家存活/死亡率**: (B) 應能將存活率控制在一個目標區間(e.g., 60%-80%)，而 (A) 可能會極高或極低。
3. **玩家受困次數**: (B) 應顯著低於一個「過難」的靜態迷宮。
4. **人類玩家滿意度**: (若時間允許) 我們將招募受試者分別遊玩 (A) 和 (B)，並填寫關於挑戰性、趣味性與挫折感的李克特量表問卷。

## 4 Appendix

為了強化本研究之實作可行性與參考性，以下整理與本專案主題(強化學習、迷宮生成、動態難度調整)高度相關的開源實例與框架：

### 4.1 相關開源框架

**OpenAI Gymnasium**: 建立強化學習環境的標準框架，支援自定義迷宮與觀測空間。

 <https://gymnasium.farama.org>

- **Stable-Baselines3**: 整合多種 RL 演算法

(如 DQN、PPO、A2C)，可用於訓練「迷宮之主」智能體。

 <https://github.com/DLR-RM/stable-baselines3>

- **PCGRL (Procedural Content Generation via RL)**: 提供以強化學習生成遊戲關卡的範例，與本研究概念一致。

 <https://github.com/smearle/control-pcgrl>

- **MazeLab**: 可快速建立與可視化格子型迷宮環境，支援與 Gym 整合。

 <https://github.com/zuoxingdong/mazelab>

- **TensorBoard / Weights & Biases**: 可用於記錄訓練過程、Reward 曲線與學習曲線。

 <https://www.tensorflow.org/tensorboard>

### 4.2 相關研究與實驗實例

- **PCGRL 迷宮生成案例**: Smearle 等人以 RL 為基礎生成遊戲關卡的研究，展示智能體能根據玩家行為調整關卡結構。

 <https://ojs.aaai.org/index.php/AIIDE/article/view/7416/7341>

- **RL-based Dynamic Difficulty Adjustment**: Andrade 等人(2006)提出的動態遊戲平衡實驗，作為傳統規則式 DDA 的經典對照研究。

 <https://dl.acm.org/doi/10.1145/1178823.1178871>

- **Unity ML-Agents 迷宮訓練範例**: Unity 官方提供之 3D 迷宮訓練環境，展示 DQN 智能體如何學習探索與找出口。

 <https://github.com/Unity-Technologies/ml-agents>

- **Memory Maze (長期記憶迷宮)**: Jurgis Petraitis 所設計的 Memory Maze，用於測試 RL 智能體在複雜迷宮中的記憶與策略。

[🔗 https://github.com/jurgisp/memory-maze](https://github.com/jurgisp/memory-maze)

以上框架與實例可作為本專案在實作階段的參考依據。特別是 PCGRL 與 Stable-Baselines3，可作為訓練「迷宮之主」智能體的主要工具，而 MazeLab 與 Unity ML-Agents 則可提供視覺化環境與模擬平台，以利後續系統驗證與展示。

## 5 Reference

- [1] Summerville, A., Snodgrass, S., Guzdial, M., et al. (2018). "Procedural content generation via reinforcement learning (PCGRL)." *IEEE Conference on Games (CoG)*.
- [2] Andrade, G., Ramalho, G., Santana, H., and Corruble, V. (2006). "Dynamic game balancing: An evaluation of user satisfaction." *Proceedings of the 2006 ACM SIGCHI international conference on Advances in computer entertainment technology*.
- [3] Yannakakis, G. N., & Togelius, J. (2018). *Artificial Intelligence and Games*. Springer.
- [4] Mnih, V., Kavukcuoglu, K., Silver, D., et al. (2015). "Human-level control through deep reinforcement learning." *Nature*, 518(7540), 529–533.
- [5] Pathak, D., Agrawal, P., Efros, A. A., and Darrell, T. (2017). "Curiosity-driven exploration by self-supervised prediction." *IEEE Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*.